

Проект «Формула цифрового счастья»

Введение и актуальность

В социологии уровень счастья – это интегральный показатель. В эпоху цифровизации социальные сети становятся «зеркалом» эмоционального и социального состояния человека.

Актуальность проекта заключается в создании инструмента, способного количественно оценить этот субъективный показатель на основе открытого цифрового следа (текстов, паттернов активности, социальных связей), не прибегая к прямому анкетированию.

Цели и задачи проекта

Цель: Разработать комплексную математическую метрику на основе многомерного анализа социальной активности пользователей ВКонтакте и доказать эффективность применения методов Deep Learning для оценки эмоционального фона контента.

Задачи:

1. Собрать выборку данных (от 100 до 200 пользователей) через VK API, включая сегментацию по возрасту (целевая группа 18-35 лет) и географии (крупные города РФ).
2. Провести предобработку данных: очистка текстов, фильтрация выбросов (исключить спам-посты, ботов).
3. Организовать ML-эксперимент. Сравнить качество работы классических моделей машинного обучения (TF-IDF + линейные модели) и нейросетевых подходов (Deep Learning) в задаче анализа тональности русскоязычных текстов.
4. Сформировать и обосновать весовые коэффициенты математической формулы Индекса счастья.
5. Провести сегментированный анализ (гендерный, возрастной) и визуализировать результаты.

Этический протокол исследования

Проект строго соблюдает нормы цифровой этики и правила использования VK API:

Открытость: Сбор данных осуществляется исключительно из публичных профилей (is_closed: False).

Приватность: Личные сообщения, закрытые фотографии и скрытые списки друзей не запрашиваются и не анализируются.

Деперсонализация: В итоговом датасете (data.json) и аналитическом отчете пользователи фигурируют в виде обезличенных идентификаторов (ID). ФИО не используются для расчета метрик.

Описание данных

Входные данные: структура формата JSON, формируемая в процессе работы скрипта-парсера. (Либо готовые данные, которые обещали предоставить VK). Начальный объем: около 150-200 профилей. Потом возможно дополнение информации.

Категории признаков:

1. Количественные показатели (Social Graph): объем социальных связей (количество друзей, подписчиков), количество подписок на сообщества.
2. Показатели активности (Activity): количество собственных постов, количество репостов (отфильтровываются при анализе тональности).
3. Качественные показатели (Content): сырые тексты постов пользователя для дальнейшего NLP-анализа, описания сообществ для определения их тематики (хобби, образование, негатив).
4. Демография: возраст (высчитывается из bdate), пол, город.

Программная и аппаратная архитектура

Аппаратная часть:

Для сбора данных и базовой аналитики используются локальные вычислительные мощности (стандартный ПК/ноутбук). Для этапа применения DL-моделей (получение эмбедингов, работа с RuBERT/Dostoevsky) планируется использование облачных сред (Google Colab) с GPU-акселерацией (NVIDIA T4) для ускорения инференса нейросетей.

Программная архитектура (Стек технологий):

Язык: Python 3.10+

Data Engineering (Сбор): vk_api (авторизация, обход лимитов), json, tqdm.

Data Science (Аналитика): pandas (структурирование данных), numpy (математические операции, нормирование шкалы Мин-Макс).

NLP & Deep Learning: NLTK/pymorphy2 (предобработка), scikit-learn (классическое ML), Dostoevsky / transformers (DL-анализ тональности).

Визуализация: matplotlib, seaborn.

Анализ и обоснование выбора инструментов (ML vs DL)

1. Сбор данных: Использование официальной библиотеки vk_api удобнее HTTP-запросов через requests, так как она автоматически обрабатывает капчу, перерывы соединения и упрощает передачу токенов.
2. Архитектура внедрения DL:

В рамках проекта стоит задача определения эмоционального окраса и тональности постов.

- ★ **Классический подход:** Bag of Words или TF-IDF в связке с логистической регрессией. *Проблема:* классический ML игнорирует контекст, иронию и сленг. Такой подход не поможет определить
- ★ **Выбранный подход (DL):** Использование архитектур на базе FastText (библиотека Dostoevsky) или трансформеров (предобученные модели RuBERT из HuggingFace / DeepPavlov). Это поможет улавливать контекст, морфологию русского языка и сленг.
- ★ **Решение:** Проект будет содержать сравнительный анализ (A/B тест на тестовой выборке). Численно докажем (через метрики F1-score), что DL превосходит классический ML для задачи «цифрового счастья», и именно предсказания DL-модели лягут в основу итоговой математической формулы.

Концепция математической модели (Формула)

Оценка счастья не может сводиться к простому суммированию лайков.

Разрабатываемая модель опирается на формулу:

$$Happiness_Index = \alpha_1 \cdot S_{network} + \alpha_2 \cdot S_{activity} + \alpha_3 \cdot S_{sentiment}$$

Где:

$S_{network}$ — нормированный показатель социальных связей (с фильтрацией выбросов через квантили, чтобы отсеять пользователей с 10 000+ "мертвых" друзей).

$S_{activity}$ — частота взаимодействия с платформой (посты/репосты).

$S_{sentiment}$ — Ключевой показатель (вес α_3 будет наибольшим): доля позитивно окрашенного авторского контента, определенная с помощью Deep Learning модели. Учитывается штрафной коэффициент за наличие токсичных/депрессивных сообществ.

Все показатели будут приведены к единой шкале [0, 1], а веса (α_1 , α_2 , α_3) будут обоснованы социологическими паттернами.

Ожидаемые результаты и ограничения

Результат:

- ☐ Рабочий скрипт парсинга,
- ☐ Сформированный data.json
- ☐ Python-ноутбук с аналитикой и итоговый аналитический отчет с визуализацией сегментов.

Ограничения модели: Необходимо учитывать концепцию "витрины социальных сетей". То есть то, что пользователи склонны транслировать "успешный успех" и маскировать реальные негативные эмоции. Модель оценивает именно цифровое благополучие,

которое может иметь погрешность по отношению к реальному психологическому состоянию.